

## RESUMEN

Este estudio implementa dos modelos de machine learning para garantizar vuelos seguros de drones. El primero utiliza el método Bootstrap con umbrales críticos de viento ( 23 km/h) y visibilidad ( 2.5 km), alcanzando una precisión del 84.7 %. El segundo corresponde a una Red Neuronal Recurrente (SimpleRNN), que analiza secuencias climáticas de 10 días para clasificar las condiciones operativas en tres categorías: Volar, Alerta o Cancelar. La combinación de ambos enfoques ofrece una herramienta robusta para apoyar la toma de decisiones operativas en la navegación de drones.

## INTRODUCCIÓN

Para volar un dron de forma segura, las condiciones climáticas son un factor clave. En este trabajo se emplea inteligencia artificial para predecir variables meteorológicas mediante una red neuronal recurrente (SimpleRNN), y se evalúa la confiabilidad del modelo utilizando la técnica Bootstrap a partir de datos históricos. El objetivo es desarrollar un sistema que ayude a determinar si es seguro realizar un vuelo, minimizando los riesgos asociados.

## OBJETIVO

Diseñar, implementar y evaluar un sistema dual de modelos de aprendizaje máquina que:

- Evalúe condiciones climáticas instantáneas mediante regresión logística con validación Bootstrap para precisión e incertidumbre.
- Prediga seguridad operacional clasificando secuencias temporales en tres categorías (Volar, Alerta, Cancelar) usando SimpleRNN para capturar dependencias temporales.

## METODOLOGÍA

### BOOTSTRAP Y REGRESIÓN LOGÍSTICA

**Datos:** Dataset sintético (200 observaciones) con viento ( $V \sim U(0, 60)$ , km/h), humedad ( $H \sim U(30, 100)$ , %) y visibilidad ( $Vis \sim U(1, 10)$ , km).

**Modelo:** Regresión logística para clasificación “Vuelo Seguro”.

**Evaluación:** Bootstrap (200 remuestreos) para accuracy e intervalo de confianza del 95 %.

### RED NEURONAL RECURRENTE (SimpleRNN - TensorFlow/Keras)

**Datos:** 2000 secuencias temporales (10 pasos, 5 variables climáticas): Temperatura ( $T \sim U(15, 30)$  °C), Humedad ( $H \sim U(30, 60)$  %), Viento ( $V \sim U(0, 20)$  km/h), Lluvia ( $L \sim U(0, 2)$  mm) y Presión ( $P \sim U(1005, 1015)$  hPa).

**Arquitectura:**

- *SimpleRNN (32 unidades):* Activación tanh, Regularización L2 (0.01), Dropout (0.2), Recurrent Dropout (0.2).
- *Dense (16, ReLU):* Capa completamente conectada con regularización por dropout.
- *Dropout (0.4):* Alta tasa para prevenir sobreajuste en capas densas.
- *Softmax (3):* Salida probabilística para clasificación triple.

**Entrenamiento:** El modelo se compiló con el optimizador Adam y se entrenó utilizando *categorical\_crossentropy* como función de pérdida, incorporando Early Stopping y balanceo de clases para evitar sobreajuste.

## Arquitectura de la red neuronal simple RNN






Figura 1: Arquitectiura de la red neuronal SimpleRNN

## ANÁLISIS Y RESULTADOS

El modelo bootstrasp presenta una precisión del 93 % en la clasificación de condiciones de vuelo seguro para drones, con un intervalo de confianza del 95 % de [90,5 %, 94,5 %]. Estos resultados demuestran una

capacidad predictiva consistentemente alta, validando la robustez estadística del modelo para la toma de decisiones operativas en seguridad aérea de drones.



**EFFECTIVIDAD DEL MODELO RNN** La red SimpleRNN implementada demostró un excelente rendimiento en la clasificación de condiciones de vuelo para drones, alcanzando una precisión general del 98.5 % en el conjunto de prueba. El modelo mantuvo un balance preciso en las tres clases de decisión: **volar** (99.2 %), **alerta** (97.7 %) y **cancelar** (98.5 %). El entrenamiento se estabilizó después de aproximadamente 50 épocas utilizando early stopping, mostrando una convergencia rápida y estable sin evidencia de sobreajuste, con una brecha mínima entre el rendimiento de entrenamiento y validación.

**ANÁLISIS DE VARIABLES MEDIANTE RNN** El análisis de importancia reveló que la velocidad del viento fue la variable más influyente (35.2 %), seguida por la precipitación (28.7 %), temperatura (18.9 %), humedad (12.4 %) y presión atmosférica (4.8 %). Este patrón confirma que los factores dinámicos como el viento y la lluvia tienen mayor impacto en las decisiones de vuelo que las variables estáticas como la presión.

## TRABAJOS FUTUROS Y MEJORAS PROPUESTAS

En trabajos futuros se propone mejorar el método Bootstrap incorporando variables como presión atmosférica, precipitación y nubosidad, además de aplicar nuevas estrategias de muestreo y validación para reducir la incertidumbre en las predicciones. También se plantea integrar datos reales mediante la OpenWeatherMap API, optimizando la precisión del modelo bajo condiciones auténticas. Finalmente, se propone comparar la red neuronal SimpleRNN con arquitecturas avanzadas como LSTM y GRU, con el fin de identificar la más eficiente en la predicción de vuelos seguros de drones.

## REFERENCIAS

- [1] Kim, Y., & Kim, Y. (2021). Weather-based UAV flight decision system using machine learning. DOI: 10.1109/AC-CESS.2021.3088765
- [2] Efron, B., & Tibshirani, R. J. (1993). An introduction to the bootstrap. Chapman and Hall/CRC. DOI: 10.1201/9780429246593
- [3] Lipton, Z. C., Berkowitz, J., & Elkan, C. (2015). A critical review of recurrent neural networks for sequence learning. DOI: 10.48550/arXiv.1506.00019